

從遊戲到強化學習： Library Escape 的 AI 演化之路

Python 期末專題報告 ——
打造連續時間非對稱潛行對抗平台

RL AGENT TRAINING STATUS



第一組：廖致翔、楊振國、李汪懋、許慈方



突破規則侷限：為什麼我們需要引入強化學習？


過去的侷限：規則型 AI



- ➡ 玩家摸清 Pattern 後挑戰性驟降。
- ➡ **渲染與物理模擬深度耦合**，無法加速訓練。



現在的突破：強化學習與連續時間



- ➡ **動態博弈 (Self-Play)**：策略共演化，AI 自主探索未知戰術。
- ➡ **架構解耦**：導入固定步長物理與可變渲染頻率，突破 60 FPS 瓶頸，實現**無頭 (Headless)** 高速訓練。

定義 AI 與遊戲環境的互動方式：Action Space、Observation Space 與 Action Mask



Action Space

- 主要使用 9 個離散方向：不動、上下左右、四個斜向。
- 支援 continuous action，但主力訓練使用離散 action。



Observation Space

- 玩家 / 敵人相對位置。
- 目標、出口、道具 slots。
- 時間、模式 flag、可逃脫狀態。
- 牆面 ray、前方 fan ray、導航方向。



Action Mask

- 排除撞牆方向。
- 冰凍或特殊狀態排除無效行動。
- 不合理 no-op 不讓 policy 過度使用。

將遊戲世界翻譯為 AI 可解讀的數學語言

Layer 4: 演算法層 (PPO / MAPPO)

- 模型從大量互動資料 (Reward/Obs) 中更新策略網路。




Layer 3: RL 環境介面層 (Gym/PettingZoo)

- 處理單/多智能體標準化 API (Reset, Step, Obs Space)。



Layer 2: 世界模擬層 (Physics & Game Rules)

- 連續時間浮點數座標、射線視野錐、精確碰撞。



Layer 1: 視覺渲染層 (Pygame)

- 渲染抽離，允許訓練時完全關閉視窗 (Headless) 以極大化算力。



AI 演化紀實：從盲目亂轉到高階戰術博弈

Phase 1 (04/18 - 04/19)

混沌期

原地擺爛與極速爆轉
(Bug 湧現)



Phase 3 (04/29 - 05/02)

突破期

策略湧現，玩家首勝與
「守出口」戰術



Phase 2 (04/19 - 04/21)

覺醒期

物理限制生效與敵人單
方面碾壓



Phase 4 (05/03 - 05/08)

終局期

50% / 50% 勝率，道具
運用與完美包抄



Reward Design：Collection Mode

Collection 模式

目標：在時限內最大化收集分數，敵人阻止玩家得分

敵人獎勵 Enemy	
終局 / 重大事件	
stalemate（整局無進展）	−80.0
timeout_score_denial_bonus（阻止得分至時間結束）	+150.0
stalemate_score_denial_bonus（僵局阻止得分）	+120.0
detection_event_bonus（偵測到玩家）	+10.0
阻止玩家收集	
player_collect_note_penalty	−18.0
player_collect_exam_penalty	−34.0
player_collect_powerup_penalty	−5.0
player_objective_complete_penalty	−60.0
過程 SHAPING （每步）	
primary_visible_per_step（視野內玩家）	+0.05
chase_progress_per_unit（靠近玩家）	+0.85
chase_alignment_per_step（追擊方向對齊）	+0.24
objective_guard_progress_per_unit（守目標）	+1.10
objective_guard_alignment_per_step	+0.28
search_move_per_unit（搜尋移動）	+0.22
time_penalty（時間流逝）	−0.01
wall_penalty（撞牆）	−0.15
idle_penalty（原地不動）	−0.35

玩家獎勵 Player	
終局 / 重大事件	
stalemate（整局無進展）	−80.0
timeout_score_progress_bonus（時間結束高分）	+190.0
stalemate_score_progress_bonus（僵局高分）	+145.0
收集事件	
collect_note（收集筆記）	+32.0
collect_exam（收集考古題）	+54.0
collect_coffee（收集咖啡）	+10.0
collect_freeze（收集凍結道具）	+14.0
objective_complete_bonus（完成收集目標）	+75.0
風險 / 偵測	
detection_event_penalty（被偵測到）	−10.0
primary_seen_per_step（被視野錐看到）	−0.04
過程 SHAPING （每步）	
goal_progress_per_unit（靠近目標）	+1.60
goal_alignment_per_step（目標方向對齊）	+0.36
evade_progress_per_unit（遠離敵人）	+0.18
evade_alignment_per_step（逃離方向對齊）	+0.05
time_penalty（時間流逝）	−0.018
wall_penalty（撞牆）	−0.20
idle_penalty（原地不動）	−0.34

Reward Design：Escape Mode

Escape 模式

目標：收集六本書後逃出出口，敵人阻止玩家逃脫


敵人獎勵 Enemy	
終局（最重要）	
catch_player（抓到玩家）	+ 300.0
lose_on_escape（玩家逃脫）	− 300.0
timeout_win（拖到時間結束）	+ 20.0
stalemate（整局無進展）	− 80.0
阻止玩家收集	
player_collect_note_penalty	− 15.0
player_collect_exam_penalty	− 3.0
player_collect_powerup_penalty	− 3.0
player_objective_complete_penalty	− 80.0
過程 SHAPING （每步）	
primary_visible_per_step	+ 0.05
chase_progress_per_unit（靠近玩家）	+ 1.50
chase_alignment_per_step	+ 0.36
objective_guard_progress_per_unit（守目標）	+ 0.85
objective_guard_alignment_per_step	+ 0.22
exit_guard_progress_per_unit（守出口）	+ 0.95
exit_guard_alignment_per_step	+ 0.24
search_move_per_unit（搜尋移動）	+ 0.25
time_penalty	− 0.02
wall_penalty	− 0.15
idle_penalty	− 0.40

玩家獎勵 Player	
終局（最重要）	
escape（成功逃脫）	+ 380.0
caught（被抓到）	− 320.0
timeout_loss（時間到未逃脫）	− 45.0
stalemate（整局無進展）	− 80.0
收集事件	
collect_note（收集必要筆記）	+ 48.0
collect_exam（收集考古題）	+ 10.0
collect_coffee（咖啡加速）	+ 12.0
collect_freeze（凍結道具）	+ 18.0
objective_complete_bonus（六本收齊，出口解鎖）	+ 130.0
風險 / 偵測	
primary_seen_per_step（被視野錐看到）	− 0.05
過程 SHAPING （每步）	
goal_progress_per_unit（靠近目標）	+ 1.85
goal_alignment_per_step（目標方向對齊）	+ 0.44
evade_progress_per_unit（遠離敵人）	+ 0.35
evade_alignment_per_step（逃離方向對齊）	+ 0.08
time_penalty	− 0.015
wall_penalty	− 0.22
idle_penalty	− 0.30


Reward Design：反作弊機制

Anti-Exploit 反作弊機制		防止 AI 鑽漏洞，避免原地爆轉、站著不動、來回抖動	
Collection 模式		Escape 模式	
no_progress_penalty（無進展懲罰）	－0.12	no_progress_penalty（無進展懲罰）	－0.14
stationary_threshold（靜止判定門檻）	0.05 格	stationary_threshold（靜止判定門檻）	0.05 格
oscillation_path_threshold（振盪路徑門檻）	0.08 格	oscillation_path_threshold（振盪路徑門檻）	0.08 格
oscillation_net_threshold（振盪淨位移門檻）	0.04 格	oscillation_net_threshold（振盪淨位移門檻）	0.04 格
player_stationary_penalty（玩家靜止）	－0.38	player_stationary_penalty（玩家靜止）	－0.42
enemy_stationary_penalty（敵人靜止）	－0.36	enemy_stationary_penalty（敵人靜止）	－0.45
player_oscillation_penalty（玩家來回抖動）	－0.52	player_oscillation_penalty（玩家來回抖動）	－0.58
enemy_oscillation_penalty（敵人來回抖動）	－0.48	enemy_oscillation_penalty（敵人來回抖動）	－0.60
player_turn_in_place_penalty（玩家原地轉圈）	－0.22	player_turn_in_place_penalty（玩家原地轉圈）	－0.28
enemy_turn_in_place_penalty（敵人原地轉圈）	－0.28	enemy_turn_in_place_penalty（敵人原地轉圈）	－0.34
player_reverse_turn_penalty（玩家反向甩頭）	－0.14	player_reverse_turn_penalty（玩家反向甩頭）	－0.18
enemy_reverse_turn_penalty（敵人反向甩頭）	－0.18	enemy_reverse_turn_penalty（敵人反向甩頭）	－0.24


Training GUI



TensorBoard



Control GUI



Result & TensorBoard

Phase 1 混沌期：當 AI 成為「鑽漏洞大師」

原地擺爛

雙方初始化後原地
不動
(04-19 00:53)



Diagnosis

Reward 太稀疏
(Sparse Reward)



Fix

導入 Dense Reward
(追擊、逃避、目標
進度給予微小獎勵)

原地爆轉

為了狂刷視野分數，
AI 展現非人類的極
速原地旋轉
(04-19 14:34)



Diagnosis

視野獎勵漏洞與
缺乏物理慣性



Fix

加入物理「最大轉向
速度上限」與「原地
旋轉懲罰」



PHASE 1 Checkpoint Video

Mode

AI vs AI

Game mode

escape

Escape mode: objective-focused pursuit. The player must collect the required notes first, then reach the exit. Trained checkpoints should usually be played back in the same Game mode they were trained for.

Seed

☒ Deterministic checkpoint playback


☐ Record replay

Start Game

Open Replays

Open Checkpoints

Status
Playback launched



Phase 2 覺醒期： 物理限制生效與敵人的恐怖統治



敵人的快速崛起



爆轉消失後，敵人瘋狂變強。因為「追擊」任務鏈極短，敵人迅速學會將玩家逼入牆角，玩家單方面遭碾壓 (Log 04-21 03:27)。

系統平衡校正



導入「自適應訓練步數 (Adaptive Timesteps)」。因為玩家的任務鏈（收集 → 躲避 → 逃脫）遠比敵人複雜，系統動態給予弱勢方（玩家）更多的 Self-Play 訓練時間，確保雙方策略持續共演化。

PHASE 2 Checkpoint Video

Launch Mode

Mode

AI vs AI

Game mode

escape

Escape mode: objective-focused pursuit. The player must collect the required notes first, then reach the exit. Trained checkpoints should usually be played back in the same Game mode they were trained for.

Seed

☒ Deterministic checkpoint playback

☐ Record replay

Replay Path

Start Game

Open Replays

Open Checkpoints

Selected Files
Enemy checkpoint
[local enemy checkpoint path omitted]
Player checkpoint
[local player checkpoint path omitted]
Human vs Rule Enemy: no checkpoint required. Human vs Enemy Checkpoint: choose an enemy .zip model. AI vs AI: choose either or both checkpoints. Empty fields fall back to rule-based agents. Seed left blank = random reset each launch. Fill a seed only when you want reproducible playback. Deterministic playback is ON by default for stable argmax-style playback. Turn it off only when you want policy variety. Collection = score-focused stealth mode. Escape = collect required notes, then break out through the exit. Checkpoint playback should usually use the same Game mode the model was trained in. If replay recording is enabled, the session is saved as a compressed .ler.gz file.

Phase 3 突破期：AI 開竅，高階戰術意識湧現

玩家的長期規劃

玩家不再盲目逃跑，學會在躲避間隙「收集逃跑前所需要素」，大幅減少無效移動。

(Key Milestones 04/29 - 05/02)


最驚豔的發現（敵人的防守意識）

敵人意識到玩家收集完 6 本書後，放棄無效跟隨追擊，直接衝往「出口」防守等待玩家自投羅網。



歷史性的首勝

玩家成功極限閃避，拿滿 6 本書並順利逃脫！



PHASE 3 玩家取得道具 成功逃離！

Remote development session

ActivitiesTk

五 2 22:45

Library Escape Control Center

PlayTrainResultsTensorBoardLeaderboardReplayConfig

Launch Mode

Mode

AI vs AI

Game mode

escape

Escape mode: objective-focused pursuit. The player must collect the required notes first, then reach the exit. Trained checkpoints should usually be played back in the same Game mode they were trained for.

Seed

☒ Deterministic checkpoint playback

☐ Record replay

Replay Path

Start Game

Open Replays

Open Checkpoints

Selected Files

Enemy checkpoint

[local enemy checkpoint path omitted]

Browse Enemy

Player checkpoint

[local player checkpoint path omitted]

Browse Player

Human vs Rule Enemy: no checkpoint required.
Human vs Enemy Checkpoint: choose an enemy .zip model.
AI vs AI: choose either or both checkpoints. Empty fields fall back to rule-based agents.
Seed left blank = random reset each launch. Fill a seed only when you want reproducible playback.
Deterministic playback is ON by default for stable argmax-style playback. Turn it off only when you want policy variety.
Collection = score-focused stealth mode.
Escape = collect required notes, then break out through the exit.
Checkpoint playback should usually use the same Game mode the model was trained in.
If replay recording is enabled, the session is saved as a compressed .ler.gz file.

Status


Playback launched successfully — local file paths omitted in public release.

1

Windows Explorer Settings File Explorer Calendar OneDrive VS Code Docker Desktop Telegram Discord Steam OBS Studio

Phase 4 終局期：達成 50/50 勝率的完美動態平衡


玩家高階戰術 (Player)



- 📖 主動拾取非通關必要的 Exams 以獲取更高系統評分。
- ☕🧊 策略性利用道具 (Coffee 加速 / Freeze 凍結) 增加生存率。
- 👁️ 利用視野盲區大幅拉開距離。



敵人高階戰術 (Enemy)




- 💀↔️💀 主敵與輔助敵人展現高階「協同包抄」。
- ➡️➡️ 從單純的「追逐」進化為深具策略性的「路線壓迫」。

🏆 雙方勝率趨近 50/50，標誌著 Self-Play 對抗環境訓練大獲成功。 🤝

PHASE 4 玩家與敵人實力相當

Remote development session



數據佐證：這不是偶然，是 1.86 億步學習的累積


186,885,000

累積訓練步數 (Timesteps)。

72.1 天

累積 AI 模擬時間。

Reward 穩定轉正



TensorBoard 數據實證，玩家 Reward 從早期的長期負值（只會被抓），穩定攀升並轉正（學會收集與逃亡）。

Opponent Pool (對手池)




AI 會與歷史版本的對手交戰，確保策略具備泛化能力，而非過度適應單一破解法。





遊戲引擎 (Game Engine)

連續時間物理、精確碰撞、射線遮蔽演算、兩種獨立遊戲模式
(Collection/Escape)。



強化學習環境 (RL Environment)




支援 Gym / PettingZoo
雙介面、Mode-aware 觀
測空間設計、Invalid
Action Masking (避免無
效動作)。



實驗操作工具 (Experiment Tools)

圖形化介面 (GUI) 啟動
訓練、Elo 勝率排行榜、
Replay 錄製回放、
TensorBoard 無縫整合。



結語：強化學習的成敗，在於「獎勵的設計」

AI 不會自動理解人類的常識。
它只會無情地最佳化我們給予的 *Reward*。

↔ 本專題最大的挑戰與價值，是將人類的
目標精準翻譯成狀態（Observation）、
動作（Action）與獎勵（Reward）。 ↗

↗ 從原地爆轉到懂得分工包抄，證明了「程
式工程」與「演算法」的深度結合，是打
造優異 AI 的唯一路徑。 🧠